

LocaPredict SLA Guard v3 (FusionOps): análise crítica, base teórica e matemática de uma plataforma AIOps validada no tempo

Avaliação técnica independente *white-box*
(código-fonte + dataset + testes + especificações)

4 de setembro de 2026

Resumo

Este artigo analisa de forma *white-box* a plataforma AIOps **LocaPredict SLA Guard v3** e explicita o arcabouço teórico, conceitual e matemático que sustenta seu funcionamento: validação temporal walk-forward sem embaralhamento, com purga de sobreposição; engenharia causal de variáveis estritamente passadas; sanitização textual canônica com TF-IDF e LSA; codificação bayesiana de categóricas; filtro de multicolinearidade por VIF; duas cabeças de Gradient Boosting — Focal Loss para violação de SLA e mediana quantílica para tempo de resolução; calibração isotônica em bloco temporal com limiar econômico τ^* ; Grouped TreeSHAP por coalizões causais; e monitoramento por PSI com auditoria contínua e bloqueio automático. Sobre 122 543 chamados reais, a dobra cega de dezembro reporta ROC-AUC 0,9753, Brier 0,0067 com erro decil 1,45%, redução de custo de 42,3% frente ao corte estático e MdAPE de 0,99 no MTTR — este último e o piso de recall, ambos BLOCKED e divulgados, delimitando com precisão o que está provado e o que permanece em aberto.

Palavras-chave: AIOps, ITSM, validação temporal, Focal Loss, regressão quantílica, calibração, SHAP, PSI, auditoria de ML.

Sumário

1	Objeto e método	2
1.1	Base empírica	2
1.2	Framework	2
2	Validação temporal walk-forward	2
2.1	O erro I.I.D. e sua eliminação	2
2.2	Purga de sobreposição	2
3	Representação: texto e categóricas	2
3.1	Sanitização canônica	2
3.2	TF-IDF com n-gramas e LSA	3
3.3	Codificação bayesiana e VIF	3
4	As duas cabeças preditivas	3
4.1	Violação de SLA: Focal Loss	3
4.2	MTTR: mediana quantílica com diagnóstico Tweedie	3
5	Calibração e decisão econômica	3
6	Grouped TreeSHAP e monitoramento	3
7	Resultados e limites	4

1 Objeto e método

O LocaPredict SLA Guard v3 (grupo GKL, turma 2TSCOA, Challenge Locaweb 2026) é uma plataforma AIOps em FastAPI + React 18 + LightGBM para predição de risco de quebra de OLA/SLA, estimativa de tempo de resolução, forecast de demanda D+1/D+7, clusterização de ruído, explicabilidade e observabilidade MLOps, sobre **122 543 chamados reais** verificados em `locaweb_clean.parquet` ($122\,543 \times 36$, janeiro/2023 a dezembro/2025). Método: leitura integral do código, dos testes (47), das especificações e da Constituição v1.1.0, com reprodução independente de cada número aqui citado.

1.1 Base empírica

Prioridade: P4 53,2%, P3 34,1%, P2 12,8%, **P1** $n = 1$. Rótulo de violação por regra de duração: 5,16%; violação KPI observada: 0,20% (o rótulo sintético é sempre nomeado como tal). `is_fp` (encerramento sem intervenção ou ≤ 30 s): 65,6%. Durações: mediana 16,3 min, média 4 142 min (assimetria $\times 254$), com outliers de data-quality (máximo $\approx 8,8 \times 10^7$ s). Team14 concentra 75,7% dos chamados; Hosting Linux, 79,0%.

1.2 Framework

Guias de validação analítica (ICH Q2, M10, USP, CLSI) não governam software; o arcabouço aplicável é o de validação de modelos de ML: janelas temporais pré-registradas, estimativas fora-da-amostra, calibração com incerteza e trilhas de auditoria. Duas regras regem tudo: critérios congelados antes do teste e nenhum número de treino reportado como generalização.

2 Validação temporal walk-forward

2.1 O erro I.I.D. e sua eliminação

Incidentes não são independentes nem identicamente distribuídos: chegam em surtos, regimes mudam, squads aprendem. Particionamento aleatório vaza o futuro para o treino. O protocolo adotado ordena $t_1 \leq t_2 \leq \dots \leq t_N$ pela abertura e expande a janela: para cada mês de teste m^* entre os três últimos, treino = meses anteriores ao mês de calibração, calibração = mês anterior ao teste, teste = um mês cego, com aquecimento mínimo de três meses e descarte registrado de dobras degeneradas. Nenhum shuffle em nenhum ponto.

2.2 Purga de sobreposição

Rótulos de violação realizam-se no encerramento; linhas de treino cujo t_{end} invade o período seguinte são excluídas (López de Prado), com contagem divulgada por dobra. As features, por construção, usam apenas informação com $t \leq t_{\text{abertura}}$: volume trailing de 24h, velocidades de chegada em 15/60/240 min por produto e carga relativa do grupo contra baseline grupo $\times$ dia-da-semana — janelas de passado, nunca estado “ainda não resolvido”, que exigiria conhecer o futuro.

3 Representação: texto e categóricas

3.1 Sanitização canônica

Antes de vetorizar, tokens de alta cardinalidade colapsam por regex determinística e idempotente: IPv4/IPv6 $\rightarrow$ `__IP__`, hexadecimais e códigos $\rightarrow$ `__ERR_CODE__`, URLs $\rightarrow$ `__URL__`, hostnames $\rightarrow$ `__SERVER_NAME__`, UUIDs $\rightarrow$ `__UUID__`. Preserva-se o fato semântico (“havia um IP”) e elimina-se o identificador que fragmenta estatísticas.

3.2 TF-IDF com n-gramas e LSA

$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot (\log \frac{1+N}{1+\text{df}(t)} + 1)$ com uni/bi/trigramas, $\text{min_df} = 5$, $\text{max_df} = 0,8$, reduzidos por SVD truncada a $k = 50$ componentes densos. Fit exclusivo no treino da dobra. Embeddings densos multilíngues existem atrás de flag, desligados por padrão: exigiriam $\sim$ GBs de RAM/imagem e violariam a regra de portabilidade do deploy gratuito — decisão registrada, não omissão.

3.3 Codificação bayesiana e VIF

Catégoricas de alta cardinalidade (prioridade, squad, produto, ativo) usam

$$\hat{x}_{\text{cat}} = \frac{n\bar{y}_{\text{cat}} + m\bar{y}_{\text{global}}}{n + m}, \quad m = 10, \quad (1)$$

ajustada só no treino: categorias raras retraem à média global, sem overfitting e sem LabelEncoder ordinal espúrio. Multicolinearidade por Spearman ($|r| > 0,85$) e VIF manual $\text{VIF}_j = 1/(1-R_j^2) > 5$: `arrive_15m` e `arrive_60m` caíram (redundantes com a de 240 min); 7 numéricas sobreviveram.

4 As duas cabeças preditivas

4.1 Violação de SLA: Focal Loss

Sob prevalência $< 10\%$, entropia cruzada afoga-se em exemplos triviais. A cabeça classificadora minimiza

$$\mathcal{L}_{\text{Focal}} = -\alpha_t(1 - p_t)^\gamma \ln(p_t), \quad \gamma = 2,0, \quad \alpha = \text{taxa de negativos}, \quad (2)$$

com gradiente e hessiana derivados em forma fechada e verificados por diferenças finitas em teste automatizado. Early stopping na calibração, sementes e threads fixas: determinismo bit a bit.

4.2 MTTR: mediana quantílica com diagnóstico Tweedie

Para perda quadrática direta sobre minutos brutos, a Tweedie ($\text{Var}(Y) = \mu^p$, $p = 1,5$) modela a média sob cauda longa — mas o aceite é *mediano* (MdAPE), e média é o estimador errado para ele sob assimetria $\times 254$. A cabeça primária é, portanto, regressão quantílica $\alpha = 0,5$ (mediana condicional, equivariante a transformações monótonas); a média Tweedie segue como diagnóstico para planejamento de capacidade, e a via logarítmica com correção $\hat{y} = \exp(\hat{z} + \hat{\sigma}^2/2) - 1$ permanece como fallback. Decisão documentada, não improviso.

5 Calibração e decisão econômica

Escore brutos não são probabilidades. Uma isotônica monótona g ajustada *no bloco de calibração* (independente de treino e teste) minimiza $\sum (y_i - g(\hat{s}_i))^2$ e produz $\hat{p}$. O limiar é econômico:

$$\tau^* = \arg \min_{\tau} C_{FP} \cdot FP(\tau) + C_{FN} \cdot FN(\tau), \quad C_{FP} = 30, \quad C_{FN} = 600, \quad (3)$$

com o piso de recall como gate divulgado. Categorias: CRITICAL se $p \geq \tau^*$, WARNING em $[\tau^*/4, \tau^*)$, SAFE abaixo. Risco exibido: $\text{round}(100\hat{p})$.

6 Grouped TreeSHAP e monitoramento

Valores de Shapley ϕ_i somam exatamente à margem: $f(x) = \phi_0 + \sum_i \phi_i$ (testado a 10^{-4} em 100% das predições). Variáveis do mesmo fenômeno formam coalizões fechadas — sobrecarga de turno, capacidade técnica, severidade semântica — e a API retorna $\Phi_G = \sum_{j \in G} \phi_j$ por macro-causa

mais o detalhamento, eliminando disputas espúrias entre correlatas. Deriva por PSI em decis, $PSI = \sum (P_b - Q_b) \ln(P_b/Q_b)$, com KS e Holm em paralelo; a tabela `prediction_audit` confronta previsão e desfecho, um job de 24h computa Brier móvel e MdAE, e degradação > 20% bloqueia a inferência automática (503 auditado).

7 Resultados e limites

Na dobra cega de dezembro ($n = 27\,321$, 0,78% positivos): ROC-AUC 0,9753, PR-AUC 0,2588, Brier 0,0067 com erro decil 1,45% (gate PASS), custo $\tau^* = 0,04$ de R\$ 410.370 contra R\$ 710.970 do corte 0,5 (−42,3%, gate PASS). Forecast: WAPE de backtest 13,44% vs. 14,14% do baseline (Diebold–Mariano $p = 0,0029$). HDBSCAN executado de verdade recusou certificar a taxonomia (overlap mediano 0,038), rotulada baseline com contagens medidas.

Dois gates permanecem BLOCKED e divulgados: recall $@\tau^* = 0,66$ contra o piso 0,80 (conflito econômico real sob custos 20:1 e prevalência 0,78%) e MdAPE 0,99 contra < 0,18 (teto dos dados: o baseline trivial de medianas por prioridade atinge 0,998). Ganhos de −38,5% e −21,4% seguem projeções até piloto controlado. Sólido, aqui demonstrado, não significa sem limites: significa incapaz de ocultá-los.

Referências

- [1] Breiman, L. Random Forests. *Machine Learning*, 45:5–32, 2001.
- [2] Salton, G., Buckley, C. Term-weighting in automatic retrieval. *IP&M*, 24(5), 1988.
- [3] Lin, T.-Y. *et al.* Focal Loss for dense object detection. *ICCV*, 2017.
- [4] Lundberg, S., Lee, S.-I. A unified approach to interpreting model predictions. *NeurIPS*, 2017.
- [5] Shapley, L. A value for n -person games. *Ann. Math. Studies*, 1953.
- [6] McInnes, L. *et al.* HDBSCAN. *JOSS*, 2017.
- [7] Massey, F. The KS test for goodness of fit. *JASA*, 1951.
- [8] Holm, S. A sequentially rejective multiple test procedure. *Scand. J. Statist.*, 1979.
- [9] Diebold, F., Mariano, R. Comparing predictive accuracy. *JBES*, 1995.
- [10] López de Prado, M. *Advances in Financial Machine Learning*. Wiley, 2018.