

# LocaPredict SLA Guard v3

FusionOps Intelligence Platform

*Predict. Explain. Prevent. Optimize.*

Documento de Especificação Completa do Projeto

Versão 3.0 — 2026

# LocaPredict SLA Guard v3 — FusionOps Intelligence Platform

*Predict. Explain. Prevent. Optimize.*

---

## Sumário Executivo

O **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** é uma plataforma avançada de AIOps orientada por Machine Learning e Ciência de Dados, projetada para transformar a gestão de incidentes de TI de um modelo reativo e retrospectivo para um modelo preditivo, explicável e adaptativo. Este documento apresenta a especificação completa do projeto, abrangendo contextualização do problema, solução proposta, impacto esperado, benefícios, comparativo competitivo e arquitetura técnica do MVP.

---

## 1. Contextualização do Problema

### 1.1 Transformação Digital e Pressão sobre Operações de TI

Nos últimos anos, empresas digitais passaram a operar em ambientes cada vez mais complexos, distribuídos e críticos ao negócio. Plataformas online, serviços em nuvem, e-commerce, aplicações SaaS, integrações em tempo real e jornadas digitais 24x7 elevaram drasticamente a dependência de operações de TI resilientes e responsivas.

Nesse contexto, a Locaweb, como importante player brasileiro de tecnologia e serviços digitais, convive diariamente com desafios típicos de operações modernas:

- Alto volume de incidentes simultâneos;
- Múltiplos produtos e serviços com diferentes criticidades;
- Necessidade de resposta rápida a falhas;
- Pressão constante por disponibilidade;
- Necessidade de cumprimento rigoroso de SLA/OLA;
- Picos sazonais de demanda;
- Ambientes heterogêneos e dinâmicos;
- Necessidade de eficiência operacional com escala sustentável.

A gestão tradicional de incidentes, baseada apenas em monitoramento reativo, dashboards históricos e atuação manual, já não é suficiente para garantir excelência operacional em ambientes de alta velocidade.

### 1.2 O Desafio Escolhido

O desafio proposto consiste em:

Construir soluções analíticas preditivas utilizando dados históricos de ITSM para prever incidentes (D+1, D+7), risco de perda de OLA e tendências operacionais (P2 e P3), com modelagem livre, engenharia de features, classificação/clusterização e alta explicabilidade.

Trata-se de um problema altamente estratégico, pois conecta diretamente:

- Experiência do cliente;
- Estabilidade operacional;
- Produtividade interna;
- Governança de serviços;
- Reputação da marca;
- Eficiência financeira.

## 1.3 Por que esse desafio é crítico?

Em operações maduras, o custo de uma falha não está apenas no incidente em si, mas em seus efeitos indiretos:

- Aumento de backlog técnico;
- Indisponibilidade de serviços;
- Escalonamentos emergenciais;
- Retrabalho entre equipes;
- Horas extras;
- Desgaste entre áreas;
- Perda de confiança interna e externa;
- Impacto em metas operacionais.

Portanto, o verdadeiro diferencial competitivo não é apenas resolver incidentes rapidamente. É **prever antes, priorizar melhor, agir antes do rompimento e aprender continuamente com os padrões históricos**.

## 1.4 Oportunidade Estratégica

A base histórica de ITSM disponibilizada contém sinais extremamente valiosos, como:

- Prioridade do incidente;
- Produto afetado;
- Categoria e subcategoria;
- Grupo designado;
- Item de configuração;
- Timestamps completos (abertura, resolução, encerramento);
- Duração total;
- Origem do chamado;
- Status final;
- Entrada em KPI;
- Violação de KPI.

Esses dados permitem construir uma plataforma de inteligência operacional capaz de migrar a empresa de um modelo **reativo** para um modelo **preditivo e adaptativo**.

## 1.5 A Solução Proposta

Diante desse cenário, propõe-se o desenvolvimento do **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform**, uma plataforma avançada de AIOps orientada por Machine Learning e Ciência de Dados que integra:

- Previsão de incidentes D+1 e D+7;
  - Predição de risco de quebra de OLA;
  - Clusterização de padrões operacionais;
  - NLP para entendimento semântico de incidentes;
  - Detecção de regimes operacionais;
  - Monitoramento de drift dos modelos;
  - Explicabilidade executiva e técnica.
- 

# 2. Problema a ser Resolvido

## 2.1 O Principal Problema Identificado

O principal problema identificado é a **incapacidade operacional de antecipar riscos relevantes em incidentes e capacidade futura usando apenas processos reativos e análises retrospectivas**.

Em termos práticos, isso significa que muitas organizações só descobrem gargalos quando:

- O SLA já foi comprometido;
- O backlog já saiu do controle;

- Equipes já estão sobrecarregadas;
- O cliente já foi impactado;
- O volume de incidentes já explodiu;
- A causa raiz já se espalhou entre sistemas.

Ou seja:

O problema não é apenas resolver incidentes. O problema é descobrir tarde demais.

## 2.2 Desdobramento do Problema

### 2.2.1 Falta de Previsibilidade Operacional

Sem modelos preditivos, decisões de escala, plantão e priorização são tomadas por percepção subjetiva. Consequências:

- Subdimensionamento de equipes;
- Excesso de capacidade ociosa em outros momentos;
- Resposta lenta em picos operacionais.

### 2.2.2 Quebra de OLA/SLA Evitável

Diversos incidentes poderiam ser tratados preventivamente caso houvesse alerta antecipado de risco. Exemplos típicos:

- Ticket P2 parado em fila errada;
- Grupo sobrecarregado;
- Produto historicamente lento;
- Abertura em horário crítico;
- Reincidência técnica ignorada.

### 2.2.3 Operação Cega para Padrões Ocultos

Sem clusterização e NLP, a organização tende a tratar tickets iguais como eventos isolados. Exemplos:

- Múltiplos "Apache Busy Workers" ao longo da semana;
- Picos de "DNS Failure" sempre após deploy;
- Reincidência de "DB Timeout" em horários específicos.

Esses padrões escondidos representam oportunidades claras de melhoria estrutural.

### 2.2.4 Modelos Analíticos Envelhecem sem Aviso

Ambientes de TI mudam rapidamente: novos produtos, novas arquiteturas, novos times, novos tipos de incidente e mudança de comportamento dos usuários. Sem drift monitoring, modelos perdem precisão silenciosamente.

## 2.3 Evidências de Importância com Base no Dataset

A base fornecida demonstra sinais claros de um ambiente operacional propício a inteligência preditiva.

#### Exemplo real informado:

| Campo             | Valor                        |
|-------------------|------------------------------|
| Número            | INC8654273                   |
| Prioridade        | 3 — Média                    |
| Grupo             | Team14                       |
| Item Configuração | IC00001                      |
| Descrição         | Problem: Apache Busy Workers |
| Aberto por        | Monitoramento                |
| Status            | Sem Intervenção              |
| Duração           | 14 segundos                  |

Esse exemplo isolado já evidencia quatro oportunidades analíticas:

1. **Deteção de falso positivo operacional** — Chamado encerrado em 14 segundos sem intervenção humana.
2. **Padrão recorrente automatizado** — Apache Busy Workers é um tipo clássico de alerta repetitivo.
3. **Oportunidade de clusterização** — Eventos semelhantes podem formar surtos monitoráveis.
4. **Ruído que afeta foco operacional** — Mesmo tickets fora do KPI consomem atenção e podem mascarar problemas reais.

## 2.4 Impacto do Problema no Negócio

**Sem solução preditiva:**

- Mais violações de OLA;
- Maior custo operacional;
- Menor produtividade;
- Decisões tardias;
- Maior pressão sobre times;
- Menor previsibilidade gerencial.

**Com solução preditiva:**

- Atuação antecipada;
  - Melhor capacity planning;
  - Redução de violações;
  - Triagem inteligente;
  - Priorização dinâmica;
  - Operação guiada por dados.
- 

## 3. Público-Alvo

### 3.1 Visão Estratégica

O **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** foi concebido como uma plataforma corporativa de inteligência operacional para ambientes de TI de alta criticidade. Seu público-alvo principal não se limita a uma única área funcional, pois o problema de incidentes, SLA e previsibilidade operacional atravessa diferentes níveis da organização.

Dessa forma, a solução atende **usuários operacionais, gestores táticos, executivos estratégicos e áreas correlatas de governança**, formando um ecossistema integrado de decisão orientada por dados.

### 3.2 Segmentação do Público-Alvo

#### 3.2.1 Operações de TI / NOC / Service Desk / ITSM

**Perfil:** Equipes responsáveis por monitoramento contínuo, abertura e tratamento de incidentes, escalonamentos, cumprimento de SLA/OLA, restauração rápida de serviços e gestão de backlog operacional.

**Necessidades atuais:**

- Saber quais tickets têm maior risco;
- Priorizar melhor filas;
- Reduzir ruído operacional;
- Detectar surtos de incidentes;
- Antecipar sobrecarga de times;
- Melhorar tempo médio de resposta.

**Valor entregue:** Com a plataforma, essas áreas passam de um modelo reativo para um modelo preditivo, recebendo score de risco por incidente, previsão de volume por turno/dia, alertas de saturação, clusters de reincidência e recomendações de priorização.

### 3.2.2 Gestores Operacionais e Coordenadores

**Perfil:** Lideranças responsáveis por performance de squads, metas mensais, distribuição de capacidade, escalas e plantões, governança de atendimento.

**Necessidades:**

- Prever gargalos futuros;
- Comparar desempenho entre grupos;
- Agir antes de rompimentos;
- Justificar decisões com dados;
- Melhorar eficiência do time.

**Valor entregue:** Projeção de KPIs, forecast de backlog, heatmaps de performance, regimes operacionais (normal / stress / crise) e insights de capacity planning.

### 3.2.3 Diretoria / Executivos / Liderança Corporativa

**Perfil:** Executivos focados em custo operacional, qualidade de serviço, satisfação de clientes, crescimento escalável e reputação da empresa.

**Necessidades:**

- Previsibilidade;
- Redução de riscos;
- Visão consolidada;
- Eficiência financeira;
- Decisões estratégicas baseadas em evidência.

**Valor entregue:** Dashboards executivos, projeção mensal de metas, risco anual de SLA, impacto financeiro de incidentes e benchmarking entre operações.

### 3.2.4 Times de Engenharia / SRE / Infraestrutura

**Perfil:** Áreas técnicas que atuam em causa raiz, estabilidade e arquitetura.

**Necessidades:**

- Identificar incidentes recorrentes;
- Detectar falhas sistêmicas;
- Correlação entre alertas;
- Entender hotspots técnicos;
- Reduzir retrabalho estrutural.

**Valor entregue:** Clusters técnicos por causa provável, NLP semântico em descrições, reincidência por item de configuração, surtos automáticos e tendências por produto.

### 3.2.5 Ciência de Dados / Analytics / MLOps

**Perfil:** Equipes que sustentam modelos analíticos corporativos.

**Necessidades:**

- Governança de modelos;
- Drift monitoring;
- Re-treinamento controlado;
- Versionamento;
- Observabilidade analítica.

**Valor entregue:** Pipeline MLOps, monitoramento contínuo, métricas de acurácia, rastreabilidade e gestão de ciclo de vida dos modelos.

## 3.3 Público-Alvo Externo Potencial

Além do uso interno na Locaweb, a solução possui forte potencial para: provedores cloud, telecom, fintechs, e-commerce, healthtechs, SaaS B2B, data centers e operações 24x7. Ou seja, torna-se também um ativo escalável de mercado.

---

## 4. Proposta de Solução

### 4.1 Visão Geral

O **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** é uma plataforma de AIOps orientada por dados históricos de ITSM que utiliza Machine Learning, NLP e Inteligência Operacional para transformar a gestão de incidentes de reativa para preditiva.

A proposta central é simples e poderosa:

Usar o histórico operacional para prever riscos futuros, orientar decisões presentes e melhorar continuamente a operação.

### 4.2 Como a Solução Resolve o Problema

#### 4.2.1 Módulo 1 — Previsão de Incidentes (D+1 / D+7)

Utilizando séries temporais e modelos avançados, a plataforma prevê:

- Quantidade de incidentes amanhã;
- Volume para os próximos 7 dias;
- Tendência por prioridade P2/P3;
- Previsão por produto;
- Previsão por grupo designado.

**Benefício:** Permite dimensionar times antes do pico ocorrer.

#### 4.2.2 Módulo 2 — Predição de Risco de Violação de OLA

Cada novo incidente recebe um score de risco calculado em tempo real com base em:

- Prioridade;
- Horário de abertura;
- Backlog atual;
- Grupo responsável;
- Histórico semelhante;
- Categoria;
- Reincidência.

**Exemplo:**

|  | Ticket   | Risco OLA |
|--|----------|-----------|
|  | INC92341 | 89%       |
|  | INC92342 | 14%       |

**Benefício:** Atuação preventiva antes do rompimento.

#### 4.2.3 Módulo 3 — Estimativa Inteligente de Duração

A solução estima:

- Tempo provável de resolução;
- Janela pessimista;
- Janela otimista.

**Benefício:** Melhora comunicação interna e previsibilidade.

#### 4.2.4 Módulo 4 — Clusterização Operacional

Algoritmos identificam padrões escondidos como:

- Tickets falsos positivos;
- Surtos automáticos;
- Grupos cronicamente lentos;
- Incidentes recorrentes;
- Comportamentos fora do padrão.

**Benefício:** A operação passa a corrigir causas estruturais, não apenas sintomas.

#### 4.2.5 Módulo 5 — NLP Semântico

Descrições resumidas são transformadas em inteligência analítica. Exemplos detectados: Apache Busy Workers, CPU High, Timeout DB e DNS Failure.

**Benefício:** Incidentes similares passam a ser tratados como famílias técnicas.

#### 4.2.6 Módulo 6 — Regimes Operacionais

A plataforma identifica automaticamente estados como: normalidade, stress, saturação, crise e recuperação.

**Benefício:** Gestores recebem alerta antes do colapso operacional.

#### 4.2.7 Módulo 7 — Drift Monitoring

A solução monitora se o comportamento da operação mudou e se o modelo perdeu aderência.

**Benefício:** Modelos permanecem atualizados e confiáveis.

#### 4.2.8 Módulo 8 — Explicabilidade Total

Toda previsão é acompanhada de explicação clara:

Risco alto devido a backlog + histórico do grupo + horário crítico + reincidência.

**Benefício:** Confiança executiva e adoção real.

### 4.3 Diferenciais Competitivos

- **Não é apenas dashboard histórico** — É plataforma de decisão preditiva.
- **Não é caixa-preta** — Explica por que cada previsão foi feita.
- **Não é estática** — Aprende continuamente.
- **Não é isolada** — Integra operação, gestão e estratégia.

### 4.4 Resumo Executivo da Solução

A solução converte dados históricos de incidentes em alertas antecipados, previsões confiáveis e ações operacionais inteligentes.

---

## 5. Impacto da Solução

### 5.1 Visão Geral

O impacto do **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** ocorre em três níveis:

1. Impacto operacional;
2. Impacto econômico;
3. Impacto estratégico e social.

## 5.2 Impacto Operacional

### 5.2.1 Redução de Violações de SLA/OLA

Com alertas antecipados, tickets críticos recebem intervenção antes do atraso. **Resultado esperado:** redução de 25% a 35% de violações.

### 5.2.2 Melhor Priorização

As equipes deixam de atuar por ordem de chegada e passam a atuar por risco real. **Resultado:** menor desperdício, foco no que importa e maior produtividade.

### 5.2.3 Menor Backlog

Com previsão de demanda e melhor alocação. **Resultado:** filas menores, tempo médio reduzido e operação mais fluida.

### 5.2.4 Menos Incêndios Operacionais

A organização sai do modo constante de urgência. **Resultado:** ambiente mais saudável, menor desgaste de equipes e menos horas extras emergenciais.

## 5.3 Impacto Econômico

### 5.3.1 Redução de Custos Operacionais

Menos retrabalho, menos incidentes repetidos e menos escalonamentos.

### 5.3.2 Eficiência de Capacidade

Escalas melhores evitam ociosidade excessiva e sobrecarga extrema.

### 5.3.3 Proteção de Receita

Serviços mais estáveis impactam positivamente retenção e satisfação.

## 5.4 Impacto Estratégico

### 5.4.1 Maturidade Data-Driven

A empresa evolui de opinião para decisão baseada em evidência.

### 5.4.2 Escalabilidade Sustentável

Mais clientes e produtos podem ser suportados sem crescimento desproporcional de custo.

### 5.4.3 Diferenciação Competitiva

Empresas com operação previsível entregam melhor experiência.

## 5.5 Impacto para Stakeholders Internos

| Stakeholder | Impacto                    |
|-------------|----------------------------|
| Operações   | Menos caos, mais foco      |
| Gestores    | Mais previsibilidade       |
| Diretoria   | Menor risco                |
| Engenharia  | Mais visão estrutural      |
| Analytics   | Casos reais de IA aplicada |

## 5.6 Impacto para Clientes Finais

Mesmo sem visualizar a plataforma, clientes sentem os efeitos: maior disponibilidade, respostas mais rápidas, menos indisponibilidade e maior confiança nos serviços.

## 5.7 Impacto para o Mercado

A solução pode posicionar a Locaweb como referência nacional em AIOps aplicado, operações inteligentes, gestão preditiva de ITSM e uso real de IA corporativa.

## 5.8 Impacto Social Indireto

Infraestruturas digitais estáveis suportam pequenos negócios online, e-commerce, educação digital, comunicação, serviços financeiros e produtividade nacional. Quanto mais resiliente a infraestrutura, maior o benefício indireto para a sociedade.

---

# 6. Benefícios Esperados

## 6.1 Visão Executiva

Os benefícios esperados do **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** decorrem da transformação estrutural do modelo operacional de TI: de uma gestão predominantemente reativa e retrospectiva para uma gestão **preditiva, explicável, adaptativa e orientada por valor**.

Em termos objetivos, a plataforma converte dados históricos de ITSM em vantagem operacional contínua. Os ganhos esperados podem ser divididos em seis dimensões:

1. Benefícios operacionais;
2. Benefícios financeiros;
3. Benefícios estratégicos;
4. Benefícios tecnológicos;
5. Benefícios humanos e organizacionais;
6. Benefícios competitivos.

## 6.2 Benefícios Operacionais

### 6.2.1 Redução de Violações de SLA/OLA

Ao identificar tickets com alta probabilidade de atraso logo na abertura ou durante o ciclo de vida, a organização consegue agir antes do rompimento. **Resultados esperados:** redução de 25% a 35% nas violações, menor exposição contratual, melhoria de metas mensais e maior confiabilidade interna.

### 6.2.2 Priorização Inteligente de Filas

Em vez de atuar por ordem cronológica ou pressão subjetiva, a operação passa a atuar por risco real e impacto provável. **Resultados esperados:** melhor uso do esforço técnico, menor desperdício operacional, tickets críticos tratados mais cedo e aumento da produtividade por analista.

### 6.2.3 Redução de Backlog Operacional

Com previsão de demanda e balanceamento antecipado de capacidade, filas tendem a diminuir. **Resultados esperados:** menor aging de chamados, menor acúmulo em horários críticos, fluxo operacional mais saudável e maior previsibilidade diária.

### 6.2.4 Resposta Mais Rápida a Surtos

Clusters automáticos e detecção de regimes identificam eventos anormais rapidamente. **Resultados esperados:** contenção precoce de incidentes em massa, menor tempo até escalonamento correto e redução do efeito cascata.

### 6.2.5 Melhoria do Tempo Médio de Resolução

Ao fornecer similaridade histórica, padrões recorrentes e score de risco, a plataforma acelera tomada de decisão. **Resultados esperados:** menor MTTR, menor tempo de triagem e mais assertividade na primeira ação.

## 6.3 Benefícios Financeiros

### 6.3.1 Redução de Custo Operacional Direto

Menos retrabalho, menos incidentes reincidentes e melhor alocação reduzem custo total da operação. **Fontes de economia:** menos horas extras emergenciais, menos esforço desperdiçado em falso positivo, menor custo de escalonamento e menor necessidade de crescimento desordenado de equipe.

### 6.3.2 Melhor Eficiência de Capacidade

Forecasting permite planejar capacidade com antecedência. **Resultados:** menos ociosidade em baixa demanda, menos colapso em alta demanda e uso mais racional de headcount.

### 6.3.3 Proteção de Receita

Serviços mais estáveis e melhor atendimento reduzem risco de churn e insatisfação.

## 6.4 Benefícios Estratégicos

### 6.4.1 Operação Previsível e Escalável

Empresas digitais crescem melhor quando a operação cresce com inteligência, não apenas com aumento de pessoas.

### 6.4.2 Governança Orientada por Dados

Gestores passam a decidir com base em indicadores futuros e não somente em relatórios passados.

### 6.4.3 Capacidade de Antecipação

A empresa deixa de "apagar incêndios" para agir preventivamente.

### 6.4.4 Evolução da Maturidade Analítica

A plataforma cria base para próximos passos: automação inteligente, auto-remediação, copilotos operacionais e IA generativa aplicada ao suporte.

## 6.5 Benefícios Tecnológicos

### 6.5.1 Ecossistema Moderno de AIOps

Integra previsão, classificação, NLP, clusterização, monitoramento de drift e explainability.

### 6.5.2 Modelos Sustentáveis

Com drift monitoring, os modelos permanecem relevantes ao longo do tempo.

### 6.5.3 Arquitetura Extensível

Pode evoluir para multi-cloud, observabilidade completa, auto-healing e recomendação automatizada.

## 6.6 Benefícios Humanos e Organizacionais

### 6.6.1 Menor Desgaste das Equipes

Menos urgências desnecessárias e melhor previsibilidade reduzem pressão operacional.

### 6.6.2 Trabalho Mais Estratégico

Analistas deixam de atuar apenas reativamente e passam a atuar com inteligência.

### 6.6.3 Maior Confiança entre Áreas

Operações, gestão e diretoria passam a compartilhar a mesma visão analítica.

## 6.7 Benefícios Competitivos

A solução fortalece o posicionamento da Locaweb como empresa moderna, eficiente e preparada para escala.

## 6.8 Indicadores Quantitativos Esperados (Estimativa Conservadora)

| Indicador                 | Ganho Esperado |
|---------------------------|----------------|
| Violação de OLA           | -25% a -35%    |
| Backlog médio             | -20% a -30%    |
| Falsos positivos          | -30% a -45%    |
| MTTR                      | -15% a -25%    |
| Produtividade operacional | +20%           |
| Precisão de planejamento  | +30% a +45%    |

## 6.9 Síntese Executiva

O benefício central da solução é transformar custo operacional imprevisível em performance previsível e escalável.

# 7. Comparativo com a Concorrência

## 7.1 Visão Geral

O mercado possui diferentes categorias de soluções que tangenciam esse problema, porém poucas combinam simultaneamente:

- Foco em ITSM;
- Previsão multi-horizonte;
- Risco de OLA;
- Clusterização operacional;
- NLP de incidentes;
- Drift monitoring;
- Explicabilidade forte;
- Customização com dados proprietários.

O **LocaPredict SLA Guard v3** se diferencia exatamente por integrar esses elementos em uma única

plataforma orientada ao contexto real de operação.

## 7.2 Principais Grupos Concorrentes

### 7.2.1 Grupo A — Ferramentas Tradicionais de ITSM

**Exemplos:** ServiceNow, BMC Software, Atlassian (Jira Service Management).

**Forças:** Workflows maduros, catálogo de serviços, gestão de chamados e automações operacionais.

**Limitações:** Analytics preditivo geralmente limitado, pouca customização profunda em ML, explicabilidade variável e dependência de módulos premium.

### 7.2.2 Grupo B — Plataformas de Observabilidade / AIOps

**Exemplos:** Dynatrace, Datadog, Splunk, New Relic.

**Forças:** Métricas em tempo real, logs e traces, alertas técnicos.

**Limitações:** Foco principal em telemetria (não ITSM histórico), nem sempre otimizadas para OLA/KPI de chamados, custo elevado em escala e menor aderência a processos específicos de service desk.

### 7.2.3 Grupo C — BI Tradicional

**Exemplos:** Power BI, Tableau.

**Forças:** Visualização forte e adoção corporativa ampla.

**Limitações:** Normalmente retrospectivos, dependem de modelagem externa, pouca inteligência preditiva nativa e não resolvem sozinhos o problema.

### 7.2.4 Grupo D — Consultorias / Soluções Sob Medida

**Forças:** Customização alta.

**Limitações:** Custo elevado, dependência de terceiros, manutenção complexa e time-to-value lento.

## 7.3 Posicionamento Competitivo

| Critério                  | ITSM Tradicional | Observabilidade | BI Tradicional | Soluções Sob Medida | LocaPredict v3 |
|---------------------------|------------------|-----------------|----------------|---------------------|----------------|
| Gestão de Incidentes      | Alto             | Médio           | Baixo          | Médio               | Alto           |
| Forecast D+1 / D+7        | Baixo            | Médio           | Baixo          | Médio               | Alto           |
| Predição OLA              | Baixo            | Baixo           | Baixo          | Médio               | Alto           |
| Clusterização Operacional | Baixo            | Médio           | Baixo          | Médio               | Alto           |
| NLP de Tickets            | Baixo            | Médio           | Baixo          | Médio               | Alto           |
| Explainability            | Médio            | Médio           | Alto           | Variável            | Alto           |
| Drift Monitoring          | Baixo            | Médio           | Baixo          | Variável            | Alto           |
| Customização negócio      | Médio            | Médio           | Médio          | Alto                | Alto           |
| Custo-benefício           | Médio            | Baixo           | Alto           | Baixo               | Alto           |

## 7.4 Diferenciais Competitivos Reais

### 7.4.1 Construído para o Problema Específico

Enquanto concorrentes são genéricos, o LocaPredict nasce para ITSM, incidentes, OLA, backlog e capacity planning.

### 7.4.2 Combina IA Avançada + Explicabilidade

Muitos players entregam IA opaca ou BI superficial. A plataforma entrega previsão robusta, justificativa clara e confiança executiva.

### 7.4.3 Aproveita Dados Já Existentes

Não exige revolução de processos para começar.

### 7.4.4 Evolução Modular

Pode iniciar como MVP e crescer para plataforma enterprise.

### 7.4.5 Potencial de Produto Proprietário

Além de uso interno, pode tornar-se solução comercializável.

## 7.5 Benchmark Narrativo

- **Concorrente tradicional diz:** "Gerenciamos seus chamados."
- **Concorrente de observabilidade diz:** "Mostramos métricas e alertas."
- **BI tradicional diz:** "Mostramos o passado."
- **LocaPredict v3 diz:** "Prevemos o futuro operacional, explicamos riscos e melhoramos continuamente."

## 7.6 Barreiras de Entrada Criadas

Ao implementar a plataforma, a Locaweb passa a acumular ativos difíceis de replicar: histórico enriquecido, features proprietárias, modelos calibrados, padrões internos aprendidos e vantagem operacional cumulativa.

## 7.7 Síntese Final do Comparativo

O **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform** não compete apenas como ferramenta. Ele compete como **capacidade organizacional superior**. Essa é a diferença entre comprar software e construir vantagem competitiva sustentável.

---

# 8. Especificação Técnica do MVP

## 8.1 Visão Geral e Objetivo do MVP

Este briefing consolida a especificação técnica e a arquitetura do MVP do **LocaPredict SLA Guard v3 — FusionOps Intelligence Platform**. O objetivo central do MVP é validar a capacidade de migrar a operação de ITSM de um modelo puramente reativo para uma postura preditiva e explicável, atuando diretamente em quatro frentes prioritárias:

- **Predição de Risco de Quebra de OLA:** Classificação supervisionada na abertura do ticket.
- **Forecasting Operacional (D+1 / D+7):** Previsão de volume de chamados por prioridade (P2/P3) e produto.
- **Agrupamento Semântico e Detecção de Ruído:** Identificação de tickets falsos positivos e surtos repetitivos via NLP.
- **Explicabilidade Operacional:** Justificativa técnica dos fatores de risco por chamado utilizando SHAP values.

## 8.2 Arquitetura de Componentes e Fluxo de Dados

flowchart TD

accTitle: Arquitetura do MVP LocaPredict SLA Guard v3  
 accDescr: Diagrama de fluxo de dados mostrando as camadas do sistema: Data Source, Ingestão, Feature Engineering, AI/ML Core, API, UI Dashboard e MLOps.

```
A["Data Source (ITSM)"] --> B["Ingestão & Sanitização"]
B --> C["DuckDB / PostgreSQL"]
C --> D["Feature Engineering & NLP"]
D --> E["TF-IDF + Embeddings + Lags Temporais"]
E --> F["AI/ML Inference Core"]
F --> G["LightGBM (OLA) + Prophet (Forecast) + HDBSCAN (Clusters)"]
G --> H["Camada de Serviço"]
H --> I["FastAPI (REST Endpoints)"]
I --> J["UI / Dashboard (Streamlit)"]
I --> K["MLOps & Drift (MLflow + Evidently AI)"]

classDef source fill:#dbeafe,stroke:#2563eb,stroke-width:2px,color:#1e3a5f
classDef process fill:#fef9c3,stroke:#ca8a04,stroke-width:2px,color:#713f12
classDef storage fill:#dcfce7,stroke:#16a34a,stroke-width:2px,color:#14532d
classDef ai fill:#f3e8ff,stroke:#9333ea,stroke-width:2px,color:#581c87
classDef api fill:#ffe4e6,stroke:#e11d48,stroke-width:2px,color:#881337
classDef output fill:#e0f2fe,stroke:#0284c7,stroke-width:2px,color:#0c4a6e

class A source
class B,D process
class C,E storage
class F,G ai
class H,I api
class J,K output
```

### 8.2.1 Camada de Ingestão

Pipeline em batch (diário/horário) para extração de dados históricos de ITSM (prioridade, grupo, IC, duração, timestamps e descrições).

### 8.2.2 Camada de Processamento & NLP

Vetorização de texto curto via TF-IDF com redução de dimensionalidade e cálculo de atributos temporais (hora crítica, dia da semana, backlog acumulado por squad).

### 8.2.3 Camada de Inteligência (Core)

- **Classificador OLA:** Modelo tabular baseado em árvores de decisão balanceado para prever probabilidade de estouro.
- **Preditor de Demanda:** Modelo autorregressivo para projeção temporal de demanda em horizontes D+1 e D+7.
- **Motor de Explicabilidade:** Módulo SHAP local calculando os 3 principais fatores de risco de cada chamado.

### 8.2.4 Camada de Exposição (API)

Microserviço REST construído em FastAPI para servir inferências sob demanda e em lote.

### 8.2.5 Interface de Apresentação

Dashboard interativo em Streamlit com visão de triagem em tempo real e projeção de capacidade.

### 8.2.6 Governança e Observabilidade

Versionamento de modelos com MLflow e verificação periódica de drift de features com Evidently AI.

## 8.3 Especificações Técnicas (Specs)

| Módulo / Camada     | Tecnologia Selecionada | Requisitos de Performance & Parâmetros |
|---------------------|------------------------|----------------------------------------|
| Linguagem & Runtime | Python 3.11+           | Execução em containers Docker leves    |

| Módulo / Camada       | Tecnologia Selecionada       | Requisitos de Performance & Parâmetros                                       |
|-----------------------|------------------------------|------------------------------------------------------------------------------|
| Banco de Dados MVP    | PostgreSQL ou DuckDB         | Suporte a cargas colunares rápidas e queries analíticas de histórico         |
| Classificação de OLA  | LightGBM Classifier          | Inferência < 50 ms; ROC-AUC ≥ 0.80 e Recall ≥ 0.75                           |
| Forecast de Volume    | Prophet / LightGBM Regressor | WAPE ≤ 15% para projeções D+1 e D+7                                          |
| NLP & Clusterização   | Scikit-learn + HDBSCAN       | Identificação de famílias de incidentes                                      |
| Explicabilidade       | SHAP (TreeExplainer)         | Cálculo síncrono de importância local das features retornado no payload JSON |
| API Backend           | FastAPI + Pydantic           | Contrato de dados validado via OpenAPI/Swagger com resposta assíncrona       |
| Frontend / Dashboard  | Streamlit                    | Atualização sob demanda com telas para Operação, Gestão Tática e Engenharia  |
| Observabilidade MLOps | MLflow + Evidently AI        | Alerta de Data Drift via teste estatístico Kolmogorov-Smirnov semanal        |

## 8.4 Métricas de Sucesso e Critérios de Aceite do MVP

- **Redução de Violação de OLA:** Identificação antecipada de tickets críticos com potencial de redução de 25% a 35% nos estouros reais.
- **Filtragem de Falsos Positivos:** Redução estimada de 30% a 45% no tempo gasto com tickets automatizados sem intervenção humana.
- **Aderência de Planejamento:** Ganho de 30% a 45% na precisão de alocação de capacidade para os times de suporte e NOC.
- **Tempo de Resposta do Sistema:** Disponibilidade dos scores de risco e explicações SHAP em menos de 2 segundos por consulta na interface web.

## Glossário

| Termo | Definição                                                            |
|-------|----------------------------------------------------------------------|
| SLA   | Service Level Agreement — Acordo de Nível de Serviço                 |
| OLA   | Operational Level Agreement — Acordo de Nível Operacional            |
| ITSM  | IT Service Management — Gestão de Serviços de TI                     |
| NOC   | Network Operations Center — Centro de Operações de Rede              |
| SRE   | Site Reliability Engineering — Engenharia de Confiabilidade de Sites |
| MLOps | Machine Learning Operations — Operações de Machine Learning          |
| NLP   | Natural Language Processing — Processamento de Linguagem Natural     |
| SHAP  | SHapley Additive exPlanations — Método de Explicabilidade de IA      |

| Termo     | Definição                                                               |
|-----------|-------------------------------------------------------------------------|
| MTTR      | Mean Time To Resolution — Tempo Médio de Resolução                      |
| WAPE      | Weighted Absolute Percentage Error — Erro Percentual Absoluto Ponderado |
| D+1 / D+7 | Previsão para amanhã / Previsão para os próximos 7 dias                 |
| P2 / P3   | Prioridade 2 (Alta) / Prioridade 3 (Média)                              |
| AIOps     | Artificial Intelligence for IT Operations — IA para Operações de TI     |
| KPI       | Key Performance Indicator — Indicador-Chave de Desempenho               |
| MVP       | Minimum Viable Product — Produto Mínimo Viável                          |

*Documento elaborado para o projeto LocaPredict SLA Guard v3 — FusionOps Intelligence Platform.*