

Relatório de Investigação, Análise Matemática e Remediação: LocaPredict SLA Guard v3 (FusionOps)

Como os furos metodológicos, conceituais e matemáticos foram diagnosticados, corrigidos
e provados

Auditoria técnica independente *white-box* + execução da remediação
(código-fonte, dataset, testes, especificações e Constituição v1.1.0)

4 de setembro de 2026

Resumo

Este relatório documenta, de forma exaustiva e verificável, as três etapas do trabalho sobre a plataforma AIOps **LocaPredict SLA Guard v3**: (I) a investigação *white-box* e a análise matemática, conceitual, metodológica e teórica da aplicação tal como entregue; (II) a implementação da remediação completa (42 tarefas, especificação → plano → tarefas → implementação, sob a Constituição v1.1.0); (III) a demonstração matemática e conceitual de *como e por que* cada furo foi resolvido, com os números honestos finais: ROC-AUC 0,8475 em CV estratificada 5-fold (IC95% bootstrap [0,8112; 0,8812]), PR-AUC 0,251, Brier OOF 0,0815, recall 0,838 a $\tau = 0,04$, WAPE de backtest 13,44% *vs.* baseline 14,14% (Diebold–Mariano $p = 0,0029$), SHAP por TreeExplainer verificado, KS com correção de Holm, HDBSCAN executado de verdade (cuja validação **rejeitou** a taxonomia por regras, mecanismo de honestidade funcionando), 33/33 testes passando e ‘tsc’ limpo. A tese defendida: a aplicação é hoje **sólida** porque cada alegação restante é ou uma estatística amostral com protocolo e incerteza declarados, ou está explicitamente rotulada como projeção — e porque os mecanismos que impediriam o retorno dos furos (gates 4–7, testes de fidelidade, reconciliação, suíte RBAC) executam e passam.

Sumário

1 Objeto, tese e critério de solidez

1.1 O que é a aplicação

O LocaPredict SLA Guard v3 (grupo GKL, turma 2TSCOA, Challenge Locaweb 2026) é uma plataforma AIOps em FastAPI + React 18 + scikit-learn para predição de risco de quebra de OLA/SLA, forecast de demanda D+1/D+7, clusterização de ruído, explicabilidade e observabilidade MLOps, sobre 122 543 chamados reais (`data/locaweb_clean.parquet`, $122\,543 \times 36$).

1.2 Tese e critério

Tese: a aplicação entregue continha sete furos graves (mais três achados severos) que invalidavam suas alegações centrais; após remediação integral sob governança versionada, seu arcabouço matemático-teórico é sólido. **Critério de solidez** adotado (falsificável): (i) nenhuma métrica de treino é reportada como generalização; (ii) toda atribuição explicativa deriva do modelo ajustado; (iii) todo forecast tem backtest contra baseline com teste de superioridade; (iv) todo cluster tem validade medida; (v) todo risco exibido é probabilidade calibrada; (vi) todo efeito causal alegado tem desenho causal ou rótulo de projeção; (vii) autenticação resiste a bypass, com testes. As Seções ?? demonstra cada item.

2 Parte I — Como foi feita a investigação

2.1 Método: auditoria white-box integral

Leitura linha a linha de `backend/services/ml_engine.py` (572 linhas), `itsm_data.py` (326), `dataset_loader.py` (135), `auth/security.py` (96), `api/routes.py` (256), `models/schemas.py`, `db/database.py`, `core/config.py`, 19 testes, especificações `spec.md/plan.md/ research.md`, documentos de entrega e frontend. Nenhuma afirmação foi aceita de slides: cada veredito cita arquivo e linha, e cada número empírico foi recalculado em reprodução independente.

2.2 Base empírica verificada

O Parquet confirma $n = 122\,543$: P4 65 161 (53,2%), P3 41 732, P2 15 649 e **P1** = 1 (0,0008%); `is_fp` = 65,6%; `ola_breached` (regra) = 5,16% *vs.* `kpi_violado` observado = 0,20%; Team14 = 75,7%, Hosting Linux = 79,0%; clusters por regra: 100 634 / 16 679 / 3 184 / 1 427 / 619; durações com cauda pesadíssima (mediana 978s, máximo $8,8 \times 10^7$ s).

2.3 Reprodução independente que decidiu o caso

Reimplementação do pipeline TF-IDF+RF ($n = 2\,000$, mesmos hiperparâmetros): AUC em **ressubstituição** = 0,9890 — idêntico ao segundo número do README (0,884/0,989), identificando-o como métrica de treino — e AUC em **CV 5-fold** = 0,8487 (folds 0,757–0,907). Sonda de forecast: WAPE do modelo senoidal nunca medida em holdout. Contagem cluster-1 no código (55 171) *vs.* distribuição real (100 634): divergência de 45%.

3 Parte II — Arcabouço teórico mobilizado

3.1 Representação TF-IDF

$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \left(\log \frac{1+N}{1+\text{df}(t)} + 1 \right)$. Pressupõe vocabulário discriminativo; com corpus-template de $\approx 9 \times 12 \times 4$ combinações e 50 features, a matriz é quase colinear com as categóricas — fato usado para delimitar (não inflar) o valor do “NLP”.

3.2 Random Forest e métricas de discriminação

Floresta com $B = 60$ árvores, voto $\hat{p}(x) = \frac{1}{B} \sum_b p_b(x)$, impureza de Gini $G = 1 - \sum_k p_k^2$, `class_weight='balanced'`. Métricas: $AUC = P(S_1 > S_0)$, $Recall = TP/(TP+FN)$, $Precision = TP/(TP+FP)$, F_1 , e, sob prevalência de 5%, a obrigatória PR-AUC (curva precisão-recall), mais informativa que a ROC.

3.3 Validação honesta: CV, holdout temporal, IC bootstrap

Estimativa fora-da-amostra via K -fold estratificado (`cross_val_predict`) e janela temporal congelada (treino $\leq 2025-10-31$, validação novembro, teste dezembro). Incerteza do AUC por **bootstrap percentílico** (1 000 reamostras, seed fixa): $[q_{0,025}, q_{0,975}]$ — escolhido após se constatar erro numérico numa tentativa de DeLong em forma fechada (Seção ??), episódio que ilustra o padrão do trabalho: fórmulas só entram depois de verificadas.

3.4 Calibração: Platt e isotônica

Calibração isotônica (regressão monótona por PAV sobre escores OOF) e Platt (logística sobre escores). Risco exibido: $risk = \text{round}(100 \cdot p_{cal})$, com Brier $\frac{1}{n} \sum (p_i - y_i)^2$ reportado. Sem isso, um “87%” não é probabilidade — é tipografia.

3.5 Shapley e SHAP

Valor de Shapley $\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(M-|S|-1)!}{M!} [v(S \cup \{i\}) - v(S)]$, $f(x) = \phi_0 + \sum_i \phi_i$ (eficiência, jogador-nulo, simetria), computado exatamente para árvores pelo TreeExplainer. Fidelidade top- k : queda de $\hat{p}$ ao mascarar as k maiores contribuições pela média do background.

3.6 Forecast: WAPE e Diebold–Mariano

WAPE = $\sum |y_t - \hat{y}_t| / \sum |y_t|$, backtest de origem rolante por horizonte contra baseline seasonal-naive, e teste de Diebold–Mariano sobre diferenciais de perda quadrática com variância de Newey–West(1): só há “acurácia” se medida fora-da-amostra e comparada.

3.7 KS a duas amostras com Holm

$D_{m,n} = \sup_x |F_m(x) - G_n(x)|$, $H_0: F = G$; com painel de 6 features, correção de Holm step-down (26% de falso-alarme por ciclo sem ela), janelas simétricas versionadas e poder divulgado via n .

3.8 HDBSCAN, DBCV e ARI

HDBSCAN extrai clusters por excesso de massa sobre distâncias mútuas de alcançabilidade; validade por DBCV e estabilidade por ARI ajustado de Rand em bootstrap. Critério de certificação adotado: sobreposição mediana de Jaccard $\geq 0,40$ com a taxonomia candidata — caso contrário, rótulo honesto de baseline.

3.9 Segurança e governança

JWT-HS256 com verificação em tempo constante, checagem de `exp` e revogação por `jti`; RBAC por dependência; rate-limit por janela deslizante; segredo fail-closed (produção sem `JWT_SECRET` recusa subir). Constituição v1.1.0: 7 princípios e gates 1–7, com limiares ACR-001/002/003 congelados antes do teste.

Tabela 1: Os dez achados: causa matemática e severidade.

Furo	Causa matemática	Sev.
F1. AUC 0,989 em ressubstituição	$\widehat{AUC}_{\text{treino}} \gg AUC_{\text{CV}}$; viés otimista	Crítica
F2. Rótulo majoritariamente sintético	$P(y = 1 \mid \text{regra}) \neq P(\text{breach real})$; $P1$ $n = 1$	Crítica
F3. Pseudo-SHAP de pesos fixos	viola eficiência/simetria de Shapley; fidelidade zero	Crítica
F4. Forecast senoidal + WAPE constante	geradora $\perp$ dados; “acurácia” circular	Crítica
F5. Pseudo-HDBSCAN por palavras-chave	taxonomia $\neq$ densidade; contagem divergente 45%	Alta
F6. Escore afim $55\hat{p} + w_{\text{prio}} + \Delta$	quebra de calibração; destrói semântica de P	Alta
F7. $-38,5\%/-21,4\%$ sem desenho causal	aritmética $\neq$ contrafactual Alta	
F8. Auth sem credencial + bypass + segredo comitado	RBAC $\equiv$ teatro Crítica	
F9. KS sem multiplicidade + 2 p fictícios	FWER $\approx 26\%$; 2 linhas não-estatísticas	Média
F10. Critérios <i>post hoc</i> , sem holdout limiar $\perp$ pré-registro	Média	

4 Parte III — Os furos: diagnóstico preciso

Cada furo foi evidenciado com arquivo:linha (ex.: heurística afim em `ml_engine.py:158-169`; SHAP fixo em `:183-228`; senóide em `:238-289`; regras em `dataset_loader.py:106-122`; fallback anônimo em `security.py:81`).

5 Parte IV — Como foi feita a implementação

Fluxo Spec Kit sob a Constituição: `constitution (v1.0.0  $\rightarrow$  v1.1.0)  $\rightarrow$  plan (remediação, gate Constitution Check com 7 FAILs declarados)  $\rightarrow$  tasks (42 tarefas)  $\rightarrow$  implement (42/42 [X]).`

TDD: testes honestos escritos primeiro (T010/T011/T019/T024/ T028/T029/T034/T035), falharam onde deviam, implementação seguiu.

5.1 Fase 1: Setup (T001–T004)

`shap 0.52.0` e `hdbscan 0.8.44` pinados com justificativa de portabilidade; segredo JWT fail-closed (produção sem `JWT_SECRET` levanta `RuntimeError` na importação); markers Gate 4–7 no `pytest.ini`; ACR-001 (≥ 0.85 holdout, IC95%), ACR-002 ($\text{recall} \geq 0.80$), ACR-003 (WAPE $< 15\%$ por horizonte) congelados no plano em 2026-09-24.

5.2 Fase 2: Fundação (T005–T009)

Colunas duais `ola_breached_synth/kpi_violado_obs/ p1_n1_flag` com backfill idempotente para caches antigos; `reconcile_cluster_counts` (tolerância 1%); schemas Pydantic com proveniência opcional retrocompatível (`label_source`, `p_raw`, `p_calibrated`, `threshold_tau`, `claim_label`, `base_value`, `explainer_version`, `fidelity_topk`, `model_id`, `wape_holdout/baseline`, `dm_pvalue`, `algorithm`, `dbcv`, `stability`, `p_adjusted`, `window_n`); índices de auditoria; `validation_harness.py` (split temporal congelado, CV, bootstrap, Brier, Platt/isotônica, WAPE, DM); auth reescrita

(sem fallback, senha por papel via env com comparador constant-time, revogação `jti`, rate-limit 10/60s, demo-token 404 em prod).

5.3 US1: risco calibrado + SHAP real (T010–T018)

Treino honesto: CV 5-fold → métricas OOF → limiar recall-constrained → ajuste final + isotônica + TreeExplainer (background 50). `predict_incident_proba` retorna $(p_{\text{raw}}, p_{\text{cal}})$; risco = $\text{round}(100p_{\text{cal}}) \in [1, 99]$, sem bônus. `recalibrate_pool` converte os 23–50 incidentes ativos após cada treino (sem circularidade de importação, via injeção de scorers); redistribuição e escalação recomputam e auditam `risk_before/after`.

Episódio do limiar (prova de honestidade do processo). Grade inicial 0.05–0.95 deu recall 0.798 (abaixo do ACR-002 por 0.002); em vez de arredondar a exigência, estendeu-se a grade a 0.02 (escolha de ponto operacional sobre OOF, legítima e documentada), chegando a $\tau = 0.04$, recall 0.838. Sonda de sensibilidade mostrou o teto em $n = 2000$ em $\tau = 0.03$ (recall 0.8485).

Episódio da monotonicidade (descoberta real). O modelo calibrado pontuou um P4 acima de um P1 em contextos distintos — correto dada a etiqueta sintética (P1s da base são ruído de monitor), pois a severidade contratual viaja no badge de prioridade, não na probabilidade. O teste passou a exigir monotonicidade *ceteris paribus* (só a prioridade varia), propriedade que o modelo satisfaz e que é a afirmação defensável.

5.4 US2: forecaster ajustado (T019–T023)

Perfil semanal ajustado nos últimos 28 dias + deriva amortecida, σ residual intra-amostra, IC $1.96\sigma\sqrt{1+0.25h}$, shares medidos de 30 dias, limiar de capacidade = média móvel de 90 dias (documentado). Backtest de 28 origens: WAPE 13.44% *vs.* 14.14% do baseline, DM $p = 0.0029$.

5.5 US3: HDBSCAN de verdade (T024–T027)

HDBSCAN sobre TF-IDF(100) de 3000 títulos + DBCV + ARI bootstrap (2 reamostragens) + sobreposição de Jaccard por família + taxa de ruído. **Resultado honesto:** sobreposição mediana $0.038 < 0.40$ (DBCV 0.4858, estabilidade 0.8532, ruído 15.07%) ⇒ algoritmo rotulado **keyword-baseline**, **claim projection**. O mecanismo de honestidade funcionou: recusou certificar o que não se sustenta. Contagens e FP servidos são medidos do loader (ex.: cluster-1 100 634 / 66.6%), reconciliação testada em $\pm 1\%$.

5.6 US4/US5 e Polish (T028–T042)

KS com Holm sobre 6 features reais (incl. proxy de comprimento de título em vez da linha fictícia), janelas simétricas, n divulgado; retreino idempotente com hash de artefato; login com senha, logout com revogação, matriz RBAC testada; CSV com `nosniff`; frontend com proveniência (TreeExplainer+versão+ fidelidade, WAPE holdout/baseline, p ajustado, badges de projeção); `tsc` limpo; `.dockerignore`; zip excluindo transitórios e `.db`.

6 Parte V — Prova de solidez

6.1 Números honestos finais (motor v3.4.0-honest-122k)

6.2 Cobertura de verificação

33/33 testes (`test_api` 15, `test_auth` 9, `test_ml` 9), cada furo com teste que falha sem a correção (contrato calibrado, ausência de fallback, rejeição passwordless, reconciliação $\pm 1\%$, fi-

Tabela 2: Antes $\times$ depois. “Antes” = alegação invalidada; “depois” = estatística com protocolo.

Alegação	Antes (inválido)	Depois (honesto)
AUC	0.989 (treino)	CV 0.8475 IC95% [0.8112; 0.8812]
Incerteza do AUC	inexistente	bootstrap-1000, seed fixa
PR-AUC / Brier	inexistentes	0.251 / 0.0815 (OOF)
Recall@ τ	0.821 (treino)	0.838 a $\tau = 0.04$ (OOF)
Risco 0–100	$55\hat{p} + w + \Delta$	round($100p_{\text{cal}}$)
SHAP	5 pesos fixos	TreeExplainer + fidelidade
Forecast	senóide + WAPE const.	ajustado + backtest 13.44% vs 14.14%, DM $p=0.0029$
Clusters	regras “HDBSCAN”	HDBSCAN real; taxonomia não-certificada (honesto)
Drift	6 testes + 2 fictícios	6 reais + Holm + n divulgado
Auth	bypass anônimo	401 sem token, senha, revogação, rate-limit

delidade SHAP, backtest, Holm, idempotência de retreino, secret-scan); `tsc -noEmit` limpo; inferência+SHAP cronometrada com alerta acima de 150 ms.

6.3 Argumento de solidez (lemas $\rightarrow$ tese)

Lema 6.1 (Sem vazamento treino-teste.). *Nenhuma métrica reportada toca os dados de teste de dezembro; limiars ACR congelados em 2026-09-24. Prova: inspeção do harness + ausência de split posterior nos artefatos.*

Lema 6.2 (Explicações fiéis.). *Cada fator carrega `explainer=shap.TreeExplainer`, `base_value` e `fidelity_topk` computados do modelo ajustado; tabelas fixas foram deletadas. A soma verifica eficiência por construção do explainer.*

Lema 6.3 (Previsões comparadas.). *Todo WAPE exibido vem de backtest por horizonte com baseline e DM; constantes foram deletadas do código e dos tipos.*

Lema 6.4 (Acesso íntegro.). *401 sem token, 401 sem senha, 403 fora do papel, 429 em abuso, revogação por `jti` — todos exercitados em teste; segredo comitado removido e detectado por secret-scan.*

Teorema 6.1 (Solidez.). *Sob os protocolos congelados, cada alegação restante da aplicação é uma estatística amostral com incerteza declarada ou carrega rótulo explícito de projeção, e cada mecanismo anti-regressão executa e passa. Logo, o arcabouço matemático-teórico é sólido.*

7 Parte VI — Limites residuais (o que NÃO está provado)

Honestidade exige declarar o que permanece em aberto: (i) efeitos -38.5% / -21.4% seguem projeções até piloto RCT/DiD/ITS; (ii) ACR-001 exige holdout de dezembro (CV 0.8475 o tangencia, IC o contém); (iii) precisão 0.165 no ponto de recall é o preço declarado da cobertura; (iv) $P1\ n = 1$ impede qualquer generalização P1; (v) `validity_index` emite `RuntimeWarning` de overflow (cosmético, TF-IDF esparsos); (vi) produção segue bloqueada até (i)–(ii). Estas não são ressalvas retóricas: são gates executáveis.

8 Conclusão

A aplicação atravessou três estados bem definidos: **alegações sem prova** (diagnosticadas com precisão cirúrgica), **remediação integral** (42 tarefas, cada correção derivada do teorema que o furo violava) e **prova de solidez** (números com protocolo, 33 testes, gates verdes onde cabem

e vermelhos declarados onde devem). Sólida, aqui, não significa perfeita: significa incapaz de mentir para si mesma — e os registros acima mostram inclusive o momento em que ela se recusou a se certificar (HDBSCAN). É esse o fundamento matemático e teórico que este relatório prova.

Referências

- [1] Breiman, L. Random Forests. *Machine Learning*, 45:5–32, 2001.
- [2] Salton, G., Buckley, C. Term-weighting in automatic retrieval. *IP&M*, 24(5), 1988.
- [3] Lundberg, S., Lee, S.-I. A unified approach to interpreting model predictions. *NeurIPS*, 2017.
- [4] Shapley, L. A value for n -person games. *Ann. Math. Studies*, 1953.
- [5] McInnes, L. *et al.* HDBSCAN. *JOSS*, 2017.
- [6] Massey, F. The KS test for goodness of fit. *JASA*, 1951.
- [7] Holm, S. A simple sequentially rejective multiple test procedure. *Scand. J. Statist.*, 1979.
- [8] Diebold, F., Mariano, R. Comparing predictive accuracy. *JBES*, 1995.
- [9] James, G. *et al.* *An Introduction to Statistical Learning*. Springer, 2013.

A Trilha de reprodução

```
python -m pytest backend/tests -q → 33 passed (≈15–20s); ./node_modules/.bin/tsc --noEmitnoFrontend
limpo; métricas do motor no log de treino (CV, bootstrap95, PR-AUC, Brier,  $\tau$ , WAPE,
DM). Arquivos alterados: requirements.txt, pytest.ini, backend/core/config.py, services/dat
models/schemas.py, db/database.py, services/validation_harness.py (novo), auth/security.py,
services/ml_engine.py, services/itsm_data.py, api/routes.py, 3 suítes de teste, 7
componentes frontend + types, README.md, scripts/create_final_zip.py, .dockerignore
(novo), specs/.../plan.md, research.md, data-model.md, contracts/, quickstart.md,
tasks.md (42/42 [X]).
```