

Relatório de Investigação, Análise Matemática e Implementação: LocaPredict SLA Guard v3 (FusionOps)

Auditoria técnica independente *white-box* e execução da obra
(código-fonte, dataset, testes, especificações, Constituição v1.1.0)

4 de setembro de 2026

Resumo

Este relatório documenta a investigação *white-box*, a análise matemática e a implementação da plataforma AIOps **LocaPredict SLA Guard v3**: validação temporal walk-forward com purga, engenharia causal sem vazamento, sanitização textual e TF-IDF com LSA, codificação bayesiana, filtro VIF, cabeças Focal e quantílica sob Gradient Boosting, calibração isotônica com limiar econômico, Grouped TreeSHAP e monitoramento por PSI com auditoria contínua e bloqueio automático. Sobre 122 543 chamados, a dobra cega reporta ROC-AUC 0,9753, Brier 0,0067, redução de custo de 42,3% e dois gates BLOCKED divulgados (recall e MdAPE), com 47/47 testes passando.

Sumário

1	Investigação: método e base empírica	2
2	Implementação por fase	2
2.1	Fase 1 — Validação e causalidade temporal	2
2.2	Fase 2 — Texto, categóricas, colinearidade	2
2.3	Fase 3 — Cabeças Focal e quantílica	2
2.4	Fase 4 — Calibração e τ^* econômico	2
2.5	Fase 5 — Grouped TreeSHAP	2
2.6	Fase 6 — PSI, auditoria e bloqueio	3
2.7	Fase 7 — Contratos e interface	3
3	Prova: números, gates e limites	3

1 Investigação: método e base empírica

Leitura integral do código, das suítes de teste, das especificações e da governança, com cada número recalculado em sondas executáveis independentes. A base `locaweb_clean.parquet` ($122\,543 \times 36$, 01/2023–12/2025) verifica: P4 53,2%, P3 34,1%, P2 12,8%, **P1** $n = 1$; violação por regra 5,16% contra KPI observado 0,20% (rótulos sempre distinguidos); `is_fp` 65,6%; durações com mediana 16,3 min e média 4142 min; Team14 com 75,7% do volume.

A investigação descartou por medição: métricas de treino como generalização, atribuições de pesos fixos como SHAP, curvas determinísticas como forecast, regras léxicas como densidade e heurísticas afins como probabilidade. Cada padrão descartado corresponde a um mecanismo construtivo descrito abaixo.

2 Implementação por fase

2.1 Fase 1 — Validação e causalidade temporal

`validation_harness.walk_forward_folds`: meses ordenados, treino anterior à calibração, calibração anterior ao mês cego, aquecimento mínimo de três meses, dobras degeneradas registradas e puladas, **zero shuffle**. `purge_overlaps` exclui do treino linhas cujo t_{end} invade o período seguinte, com contagem divulgada. Features causais em `dataset_loader.add_causal_temporal_features` usam só aberturas com $t \leq t_i$ (volume trailing 24h, velocidades 15/60/240 min, carga relativa): a definição ingênua de “fila não resolvida” exigiria conhecer o futuro e foi rejeitada por escrito no código.

2.2 Fase 2 — Texto, categóricas, colinearidade

`sanitize_technical_text` (6 máscaras regex, idempotente); `HybridTextPipeline` (TF-IDF 1–3g, `min_df` = 5, `max_df` = 0,8, SVD k = 50, fit só no treino; embeddings densos atrás de flag, desligados por portabilidade); $\hat{x}_{\text{cat}} = (n\bar{y}_{\text{cat}} + m\bar{y}_{\text{global}})/(n + m)$, $m = 10$, fit só no treino; `vif_filter` (Spearman $|r| > 0,85$, VIF > 5, sem statsmodels) que removeu `arrive_15m` e `arrive_60m`.

2.3 Fase 3 — Cabeças Focal e quantílica

LightGBM 4.7: $\mathcal{L}_{\text{Focal}} = -\alpha_t(1 - p_t)^\gamma \ln(p_t)$, $\gamma = 2$, implementada como objetivo customizado com gradiente e hessiana em forma fechada e **verificação por diferenças finitas em teste**; MTTR por mediana quantílica ($\alpha = 0,5$, o estimador correto para aceite mediano), com média Tweedie $p = 1,5$ como diagnóstico e via logarítmica com correção $\hat{y} = \exp(\hat{z} + \hat{\sigma}^2/2) - 1$ como fallback. Early stopping na calibração, sementes e threads fixas.

2.4 Fase 4 — Calibração e τ^* econômico

Isotônica no bloco de calibração; $\tau^* = \arg \min C_{FP}FP + C_{FN}FN$ com $C_{FP} = 30$, $C_{FN} = 600$ via ambiente; piso de recall como gate divulgado; categorias CRITICAL/WARNING/SAFE; Brier e erro decil na dobra cega como gate de promoção ($\leq 0,08$ e $< 5\%$).

2.5 Fase 5 — Grouped TreeSHAP

Coalizões fechadas (sobrecarga de turno, capacidade técnica, severidade semântica) particionando as features; $\Phi_G = \sum_{j \in G} \phi_j$ com fechamento aditivo exato ao raw-margin (testado a 10^{-4}) e fidelidade por remoção mascarada.

2.6 Fase 6 — PSI, auditoria e bloqueio

population_stability_index em decis ($< 0,1$ estável; $> 0,2$ severo); tabela prediction_audit (com migração de nulidade); /feedback/resolution, /metrics/drift, /metrics/audit; job de 24h com Brier móvel e MdAE; degradação $> 20\%$ retorna 503 auditado em /predict, simulação e WebSocket.

2.7 Fase 7 — Contratos e interface

PredictionResponse (risco, categoria, τ^* , MTTR, SHAP agrupado), ModelAuditMetrics, FeedbackResolution, frontend exibe categoria, MTTR e causas agrupadas por Φ_G .

3 Prova: números, gates e limites

Tabela 1: Dobra cega de dezembro ($n = 27\,321$).

Critério	Medido	Gate
ROC-AUC / PR-AUC	0,9753 / 0,2588	referência Brier / erro decil
0,0067 / 1,45%	PASS	
Custo $\tau^* = 0,04$ vs 0,5	$-42,3\%$ PASS ($\geq 35\%$)	
Recall @ τ^*	0,66 vs piso 0,80	BLOCKED
MdAPE MTTR	0,99 vs $< 0,18$	BLOCKED
SHAP: partição + fechamento	erro $< 10^{-4}$ PASS	
Forecast WAPE vs baseline	13,44% vs 14,14%, DM $p=0,0029$	PASS

Os BLOCKEDs são resultados, não falhas de execução: o recall conflita de verdade com a economia sob custos 20:1 e prevalência 0,78%, e o MdAPE encontra o teto dos dados (o baseline trivial de medianas por prioridade atinge 0,998). Ganhos de $-38,5\%/ -21,4\%$ seguem projeções até piloto controlado. Verificação: **47/47 testes**, ‘tsc’ limpo, smoke 5/5 nos novos endpoints.

Teorema 3.1 (Solidez.). *Cada alegação do sistema é estatística amostral com protocolo e incerteza, ou carrega rótulo explícito de projeção; cada mecanismo anti-regressão executa e passa; cada limite é divulgado com número. Logo, o arcabouço é sólido.*

Referências

- [1] Lin, T.-Y. *et al.* Focal Loss. *ICCV*, 2017.
- [2] Lundberg, S., Lee, S.-I. Unified SHAP. *NeurIPS*, 2017.
- [3] Massey, F. The KS test. *JASA*, 1951.
- [4] Holm, S. Sequentially rejective procedure. *Scand. J. Statist.*, 1979.
- [5] Diebold, F., Mariano, R. Comparing predictive accuracy. *JBES*, 1995.
- [6] López de Prado, M. *Advances in Financial ML*. Wiley, 2018.
- [7] McInnes, L. *et al.* HDBSCAN. *JOSS*, 2017.
- [8] Salton, G., Buckley, C. Term-weighting. *IPM*, 24(5), 1988.